Document partagé "Introduction au logiciel R - 2025"

Mercredi matin: rappels

```
Installation du package du cours :
remotes::install github("vguillemot/intro2r")
> install.packages("remotes")
trying URL
'https://cran.rstudio.com/bin/macosx/big-sur-arm64/contrib/4.4/rem
otes 2.5.0.tgz'
Content type 'application/x-gzip' length 430216 bytes (420 KB)
______
downloaded 420 KB
install.packages(remotes)
Error in install.packages : objet 'remotes' introuvable
→ explication il manquait les guillemets dans la commande
Error message:
Skipping install of 'intro2r' from a github remote, the SHA1
(3cdb1c0b) has not changed since last install.
  Use `force = TRUE` to force installation
→ le package est déjà installé
> install.packages("intro2r")
Warning in install.packages:
 package 'intro2r' is not available for this version of R
A version of this package for your version of R might be available
elsewhere,
see the ideas at
https://cran.r-project.org/doc/manuals/r-patched/R-admin.html#Inst
alling-packages
→ il faut utiliser la fonction remotes::install github parce que intro2r n'est pas un package
CRAN
> remotes::install github("vguillemot/intro2r")
Downloading GitHub repo vguillemot/intro2r@HEAD
These packages have more recent versions available.
It is recommended to update all of them.
Which would you like to update?
```

```
1: All
 2: CRAN packages only
 3: None
 4: rlang
              (1.1.3 \rightarrow 1.1.5) [CRAN]
 5: glue
               (1.7.0 \rightarrow 1.8.0) [CRAN]
               (3.6.2 -> 3.6.4) [CRAN]
 6: cli
 7: withr
              (3.0.0 \rightarrow 3.0.2) [CRAN]
8: pillar
              (1.9.0 \rightarrow 1.10.1) [CRAN]
 9: colorspace (2.1-0 -> 2.1-1 ) [CRAN]
10: R6
               (2.5.1 \rightarrow 2.6.1) [CRAN]
              (0.3.5 -> 0.3.6) [CRAN]
11: gtable
Enter one or more numbers, or an empty line to skip updates:
library(remotes)
Enter one or more numbers, or an empty line to skip updates:
remotes::install github("vguillemot/intro2r")
Enter one or more numbers, or an empty line to skip updates:
remotes::install github("vguillemot/intro2r")
Enter one or more numbers, or an empty line to skip updates:
library(intro2r)
Enter one or more numbers, or an empty line to skip updates:
Running `R CMD build`...
* checking for file
'C:\Users\Libre\AppData\Local\Temp\RtmpGMQ1w6\remotes10f42f526b0c\
vguillemot-intro2r-3cdb1c0/DESCRIPTION' ... OK
* preparing 'intro2r':
* checking DESCRIPTION meta-information ... OK
* checking for LF line-endings in source and make files and shell
scripts
* checking for empty or unneeded directories
* building 'intro2r 1.0.2025.tar.gz'
Installation du package dans
'C:/Users/Libre/AppData/Local/R/win-library/4.3'
(car 'lib' n'est pas spécifié)
* installing *source* package 'intro2r' ...
** using staged installation
** R
** data
*** moving datasets to lazyload DB
** inst
** byte-compile and prepare package for lazy loading
Messages d'avis :
1: le package 'ggplot2' a été compilé avec la version R 4.3.3
2: le package 'dplyr' a été compilé avec la version R 4.3.3
** help
*** installing help indices
** building package indices
** installing vignettes
```

```
** testing if installed package can be loaded from temporary
location
Avis : le package 'ggplot2' a été compilé avec la version R 4.3.3
Avis : le package 'dplyr' a été compilé avec la version R 4.3.3
** testing if installed package can be loaded from final location
Avis : le package 'ggplot2' a été compilé avec la version R 4.3.3
Avis : le package 'dplyr' a été compilé avec la version R 4.3.3
** testing if installed package keeps a record of temporary
installation path
* DONE (intro2r)
→ tout va bien mais le dialogue ne s'est pas forcément bien passé
> remotes:install github("vguillemot/intro2r")
Error: object 'remotes' not found
→ il mangue un ":" dans remotes::install github("vguillemot/intro2r")
Avec les fonctions du package pak
pak::pak("vguillemot/intro2r")
Exercice sur les booléens
Soit le vecteur aléatoire suivant :
poids <- rnorm(100, mean = 70, sd = 10)
   1) Je veux un vecteur de booléens qui est vrai quand le poids est compris entre 65 et
     75.
Réponse :
poids entre 65 75 <- (poids >= 65) & (poids <= 75)
poids entre 65 75
Ou bien:
poids 65 75<-(poids<=75 & poids>=65)
Erreurs:
poids entre 65 75 <- (df$weight kg \geq 65) & (df$weight kg \leq 75)
→ Attention erreur : df n'existe pas
Error message: Error: unexpected '<' in "poids entre 65 75 <-
(poids >=65) & (poids=<"
> poids entre 65 75
Error: object 'poids entre 65 75' not found
→ l'opérateur "=<" n'existe pas, la bonne syntaxe est "<="
```

2) Maintenant je veux les **valeurs** de poids comprises entre 65 et 75

Méthode 1:

poids(poids<=75&poids>=65]

```
dat <- data.frame(poids)</pre>
```

Exercice : chargement et exploration des données "fruits et légumes"

1. Chargement des données

```
## Premiere possibilité : fonctionne parce que ce sont des données associées au package
data("fruveg", package = "intro2r")
## Deuxieme possibilite (utile pour les données personnelles)
library(readxl)
fruveg <- read excel("fruits and veggies.xlsx")</pre>
   2. extraire les fruits et légumes dont la teneur en eau est supérieure à 90%
eau 90 <- fruveg[fruveg$water > 90, ]
   3. extraire les fruits crus
fruits crus <- fruveg[fruveg$group == "raw fruit",]</pre>
   4. extraire les légumes cuits contenant moins de 1g/100g de sucres
legumes cuits peu sucres <- fruveg[fruveg$group=="cooked</pre>
vegetable" & fruveg$sugar < 1,]</pre>
```

Erreurs et débogage

```
> fruit veggies[fruit veggies$water>=90, ]
Error in base::nchar(wide chars$test, type = "width") :
  lazy-load database
'/Library/Frameworks/R.framework/Versions/4.4-x86 64/Resources/lib
rary/cli/R/sysdata.rdb' is corrupt
In addition: Warning messages:
1: In base::nchar(wide chars$test, type = "width") :
  restarting interrupted promise evaluation
2: In base::nchar(wide chars$test, type = "width") :
  internal error -3 in R decompress1
→ BDD de package mal chargée donc il faut redémarrer Rstudio
Error in type.convert.default(data[[i]], as.is = as.is[i], dec =
  invalid multibyte string at '<b6><85>m<9a><87>8F<82>5<
L^{d7}=-de^{a9}=de^{a9}=f^{9}=R'
In addition: Warning messages:
1: In read.table("/Users/melan/Downloads/nutrimenu.xlsx", header =
TRUE, :
 line 1 appears to contain embedded nulls
2: In read.table("/Users/melan/Downloads/nutrimenu.xlsx", header =
TRUE,
```

```
line 2 appears to contain embedded nulls
3: In read.table("/Users/melan/Downloads/nutrimenu.xlsx", header =
  line 3 appears to contain embedded nulls
4: In scan(file = file, what = what, sep = sep, quote = quote, dec
= dec.:
  embedded nul(s) found in input
→ Utilisation de read.table sur un fichier Excel, il faut utiliser autre chose
> raw fruit <- fruits and veggies[fruits and veggies$type == "raw fruit", ]</pre>
Error in `fruits and_veggies[fruits_and_veggies$type == "raw fruit", ]`:
! Can't subset rows with `fruits and veggies$type == "raw fruit"`.
★ Logical subscript `fruits and veggies$type == "raw fruit"` must be size 1
or 33, not 0.
Run `rlang::last trace() ` to see where the error occurred.
Warning message:
Unknown or uninitialised column: `type`.
→ type n'existe pas dans la base de données
fruits and veggies <- read excel("fruits and veggies.xlsx")
is.data.frame(fruits and veggies)
fv<-fruits and veggies
is.data.frame(fv)
#EXTRAIRE F&L teneur>90%
teneursup 90<-fv$water[fv$water>90]
teneur eau 90 <- fruveg$water[fruveg>90]
> crus<-fruveg[fruveg$group,raw]</pre>
Error in `fruveg[fruveg$group, raw]`:
! Can't subset columns with `raw`.
* `raw` must be logical, numeric, or character, not a function.
Run `<u>rlang::last_trace()</u>` to see where the error occurred.
Error in `fruveg[fruveg$group == "raw fruit"]`:
! Can't subset columns with `fruveg$group == "raw fruit"`.
★ Logical subscript `fruveg$group == "raw fruit"` must be size 1 or 19, not
33.
Run `rlang::last trace() ` to see where the error occurred.
→ II mangue la virgule
> cooked veggies1 <- fruits and veggies$group == "raw</pre>
fruit"[fruits and veggies$group$sugar == "cooked vegetables", ]
Error in fruits and veggies$group$sugar :
  $ operator is invalid for atomic vectors
→ on ne peut pas mettre 2 $
fv[fv$group=="cooked vegetables" & "df$sugar"<1,]</pre>
→ Double problème : les guillemets et df
```

```
fv[fv$group=="cooked vegetables" & fv$sugar<1,]
# A tibble: 0 × 19
# i 19 variables: name <chr>, group <chr>, energy <dbl>, water <dbl>,
proteins <dbl>,
# carbohydrates <dbl>, lipids <dbl>, sugar <dbl>, fibers <dbl>, alcohol
<dbl>,
# calcium <dbl>, copper <dbl>, iron <dbl>, magnesium <dbl>, manganese
<dbl>,
# phosphorus <dbl>, potassium <dbl>, zinc <dbl>, vitaminC <dbl>
→ II y a un s en trop à vegetables
```

Mercredi Après-midi: Visualisation avec ggplot2

Exercice : reproduire le graphe

```
fruveg$SucresSup5 <- fruveg$sugar > 5
Ou si on veut les appeler autrement que TRUE FALSE:
fruveg$SucresSup5 <- ifelse(fruveg$sugar > 5, "Sup 5", "Inf 5")
ggplot(fruveg,
     aes(x = SucresSup5,
         fill = SucresSup5)) +
  geom bar()
##Avec geom_bar
ggplot(fruveg, aes(group)) +
  geom bar(fill = "steelblue")
## Avec geom col
vitamine <- data.frame(</pre>
  groupe = c("compote", "crus", "exotique", "secs"),
  VitamineC = c(14.2, 12.2, 32.1, 0.3)
ggplot(
  data = vitamine,
  mapping = aes(x = groupe, y = VitamineC)) +
  geom col()
```

Exercice : diagramme en bâtons de la teneur en eau

Comment modifier le code précédent pour faire un diagramme en bâtons montrant le nombre de fruits et légumes ayant une teneur en Eau supérieure à 80 g / 100 g par groupe ?

```
fruveg$water80 <- fruveg$water > 80
ggplot(fruveg, aes(x = water80, color = group, fill =
water80)) +
 geom bar()
=> FAUX
Proposition 1
eau 80 <- fruveg[fruveg$water > 80, ]
ggplot(
 data = eau 80,
 mapping = aes(x=group, fill = group)) +
 geom bar()
Autre solution:
ggplot(
 data = fruveg,
 mapping = aes(
     x = group,
     fill = water >= 80)) +
  geom bar()
3ème solution:
library(dplyr)
#filter fruits avec water content > 80
filtered data <- fruveg %>%
 filter(water > 80)
#Create a ggplot avec le numero des fruits/group
ggplot(filtered data, aes(x = group)) +
  geom bar(fill = "steelblue") +
labs(title = Counts of fruits with water content > 80%",
x= "Fruit category"
y= "Number of fruits"
#Counting :-)
group counts <- fruveg %>%
filter(water>80) %>%
group by(group) %>%
summarise(count =n())
print (group counts)
```

```
library(dplyr)
fruveg %>%
  group_by(group) %>%
  count(water >= 80) %>%
  filter(`water >= 80`) %>%
  ggplot(aes(x = group, y = n )) +
  geom_col()
```

Histogramme de la teneur en sucre

Diagramme de Tukey

```
ggplot(data=fruveg, aes(x=group, y=sugar)) +
  geom_boxplot(fill = "pink")

bimodal <- data.frame(
  x = c(
     rnorm(100, 2),
     rnorm(100, 20)))

ggplot(bimodal, aes(x)) +
  geom histogram()</pre>
```

Exemple de données simulées bimodales

```
bimodal <- data.frame(
    x = c(
        rnorm(n = 100, mean = 2),
        rnorm(n = 100, mean = 20)))

ggplot(bimodal, aes(x)) +
    geom_histogram()

ggplot(bimodal, aes(x = x)) +
    geom_violin(aes(y = "Violon"), trim = FALSE) +
    geom_boxplot(aes(y = "Tukey"))</pre>
```

Exercice : reproduction de diagramme en violons

```
ggplot(fruveg,
    aes(x = fibers > 1.5,
        y = proteins,
        fill = ***)) +
geom_***()

ggplot(fruveg,
    aes(x = fibers > 1.5,
        y = proteins,
        fill = fibers>1.5)) + geom violin()
```

Exercice : reproduire le thème

```
ggplot(fruveg, aes(fibers)) +
  geom_boxplot() +
  theme_***()

ggplot(fruveg, aes(y=fibers)) +
  geom_boxplot() +
  theme_classic()
```

Exercice : reproduction du nuage de points

```
ggplot(fruveg,
       aes(x = sugar,
           y = proteins,
           *** = magnesium,
           *** = ***)) +
  geom ***() +
  ***(title = "Fruits et légumes",
     x = "Sucres (g/100 g)",
     y = "Protéines, N x 6.25 (g/100 g)",
     size = "Magnésium\n(mg/100 g)",
     ***= "Groupe") +
  theme ***()
nuage de point : proposition mélanie
# nuage de points
ggplot(fruveg,
      aes(x = sugar,
```

```
y = proteins,
size = magnesium,
color = group)) +
geom_point() +
labs(title = "Fruits et légumes",
x = "Sucres (g/100 g)",
y = "Protéines, N x 6.25 (g/100 g)",
size = "Magnésium\n(mg/100 g)",
color= "Groupe") +
theme_minimal()
```

Exercice: trouver les fonctions de modification d'échelle

Pour sauvegarder un graphe

```
g <- ggplot(fruveg, aes(group)) +
   geom_bar()
print(g)

ggsave(filename = "mongraphe.png", plot = g)</pre>
```

Jeudi Matin : visualisation plus avancée

Pour installer le package RColorBrewer (si besoin), utiliser la commande suivante : install.packages ("RColorBrewer")

Exercice : reproduire le diagramme en bâtons

```
# Solution 1
a <- (1:5)
barplot(c(a, a), col=c("#B4EEB4","#EEB422"))
# Solution 2
barplot(c(1:5,1:5), col=c("#104E8B", "#EE3B3B"))
# Solution 3
barplot(c(1,2,3,4,5,1,2,3,4,5),col=c("#436EEE", "#FF4040")))
# Solution 4
barplot(rep(1:5, 2), col = c(4, 2))

## Pour afficher toutes les palettes de RColorBrewer display.brewer.all()
## Pour choisir 3 couleurs de la palette "Set3"
brewer.pal(n = 3, name = "Set3")</pre>
```

Exercice : reproduire le diagramme en bâtons avec brewer.pal

```
pal <- brewer.pal(***, ***)</pre>
barplot(rep(1, 7),
        col = pal,
        axes = ***,
        border = ***)
pal <- brewer.pal(n=7, name="Set1")</pre>
barplot(rep(1, 7),
        col = pal,
        axes = FALSE,
        border = NA)
# Modification des couleurs dans ggplot
ggplot(fruveg, aes(x = group,
                   fill = group)) +
  geom bar() +
  scale fill brewer(palette = "Set1") +
  theme bw()
```

```
ggplot(fruveg, aes(x = phosphorus,
                   y = calcium,
                   color = magnesium)) +
  geom_point() +
  scale_color_distiller(palette = "PuOr") +
  theme bw()
```

Cartes de chaleur

```
library(pheatmap)
colfun <- colorRampPalette(</pre>
  c("darkorchid",
     "white",
     "limegreen"))
fruvegDF <- data.frame(</pre>
  fruveg[,-c(1, 10)],
  row.names = make.unique(fruveg$name))
annotLignes <- fruvegDF[, "group",</pre>
                      drop = FALSE
pheatmap(
  fruvegDF[, -1],
 cluster rows = FALSE,
  scale = "column",
 show rownames = FALSE,
 cellwidth = 10,
 color = colfun(20),
 annotation row = annotLignes
)
Question : pourquoi le nid d'abeille est au milieu est pas autour
des points ? merci
ggplot(data=trial,
       aes(death,age, fill = death))+geom violin()+geom beeswarm()
theme minmal()
```

Jeudi après-midi : tests et analyses statistiques

Le jeu de données "trial"

```
# Chargement des packages
library(gtsummary)
library(ggplot2)
library(ggbeeswarm)
library(performance)
# Le jeu de données trial
View(trial)
# Distribution de l'âge en fonction du stade de la tumeur
ggplot(trial, aes(stage, age, fill = stage)) +
  geom violin(trim = FALSE) +
  geom beeswarm()
# Régression logistique
res.log <- glm(response ~ trt + age + marker + stage, # modele
                data = trial, # data
                family = binomial()) # famille de modèle
# Utilisation de tbl regression
plot(res.log)
performance::model performance(res.log)
res.lm <- lm(energy ~ proteins + sugar + fibers + water,
          data = fruveq)
summary(res.lm)
tbl_regression(res.lm)
##### Autre exemple de régression logistique : les données
"diabète" ####
# lien :
https://www.sthda.com/english/articles/36-classification-methods-e
ssentials/151-logistic-regression-essentials-in-r/
## Chargement des packages
library(ggplot2)
library(gtsummary)
library(performance)
```

```
## Thème ggplot
theme set(theme bw())
## Les données de diabète
data("PimaIndiansDiabetes2", package = "mlbench")
dat.nona <- na.omit(PimaIndiansDiabetes2)</pre>
dat.nona$random <- rnorm(nrow(dat.nona))</pre>
## Modèle de régression logistique
res.log <- glm(diabetes ~., data = dat.nona, family = binomial)
res.log <- glm(diabetes ~ random, data = dat.nona, family =
binomial)
summary(res.log)
## Performance et diagnostique du modèle
check model(res.log)
tbl regression(res.log, exponentiate = TRUE)
## La fonction cut
crp < -c(10, 15, 14, 20, 45, 100, 150)
cut(x = crp,
     breaks = c(0, 10, 20, 50, 200),
     labels = c("<10", "(10,20]", "(20,50]", ">50"))
## Analyse des données nutrimenu
## Packages
library(ggcorrplot)
library(ggplot2)
library(readxl)
## Import des données
nutrimenu <- read excel("nutrimenu.xlsx")</pre>
ggplot(
  data = nutrimenu,
  mapping = aes(
     x = Nutriscore,
     y = Energie,
     color = Type)) +
  geom boxplot() +
  geom point (
     position = position dodge(width = .75)) +
  theme minimal() +
  labs(title = "Energie par Nutriscore",
```

```
x = "Nutriscore",
     y = "Energie (kcal)")
# Sélectionner les variables numériques
variables_nutritionnelles <- c("Glucides", "Lipides", "Proteines",
"Sucre", "Fibres", "Sel", "AGS", "Energie")
# Calculer la matrice de corrélation
correlation matrix <- cor(nutrimenu[, variables nutritionnelles])</pre>
# Afficher la matrice de corrélation
print(correlation matrix)
# Créer le corrélogramme
ggcorrplot(correlation matrix,
           lab = TRUE,  # Ajouter les valeurs des corrélations
dans le graphique
           lab size = 3,  # Taille des étiquettes
           type = "lower", # Afficher uniquement la partie
inférieure de la matrice (pour éviter la duplication)
          colors = c("red", "white", "blue"), # Palette de
couleurs
          title = "Corrélogramme des corrélations entre les
variables nutritionnelles",
          ggtheme = theme minimal()) # Thème minimal
## ANOVA de l'énergie en fonction du Nutriscore
anova Nutriscore <- aov(Energie ~ Nutriscore, data = nutrimenu)</pre>
summary(anova Nutriscore)
pairwise.t.test(
  x = nutrimenu$Energie,
  g = nutrimenu$Nutriscore)
performance::check model(regression model multiple)
gtsummary::tbl regression(regression model multiple)
```

Dates

```
library(lubridate)
dat1 <- ymd("2020-07-13")
dat2 <- ymd("2024-03-14")

interval_period <- interval(dat1, dat2)
full_year <- interval_period %/% years(1)
remaining_months <- interval_period %% years(1) %/% months(1)
remaining_days <- interval_period %% years(1) %% months(1) %/%
days(1)
sprintf('Your age is %d years, %d months and %d days', full_year,
remaining_months, remaining_days)</pre>
```