Commandes et objets de base, et importation

Vincent Guillemot

Mercredi

Bien se préparer à coder

- Créer un projet dans ce dossier :
  - Bien réfléchir au nom de ce projet
  - Bien réfléchir à l'endroit où ce projet sera situé
- Créer un script
- Savoir où sont les données, et sous quel format
- Savoir ce que l'on veut faire !

C’est parti pour les commandes de base !

Le(s) prompt(s)

- `>` : R attend une commande à exécuter
- `+` : la commande qui a été entrée n'est pas complète car
  - il manque une parenthèse fermante
  - il manque un crochet fermant
  - il manque une accolade fermante
- : la commande est en cours de traitement. On peut l'arrêter en cliquant sur le bouton "Stop"

Opérations de base

On peut effectuer toutes les opérations de base en R :

- addition (`+`), soustraction (`-`), multiplication (`*`), division (`/`), exponentiation (`**` ou `^`)…

appliquer les fonctions mathématiques de base :

- logarithme (`log`, `log2`, `log10`), exponentielle (`exp`) sinus (`sin`), cosinus (`cos`), tangente (`tan`)

On peut combiner les opérations et les fonctions, et gérer les priorités avec des parenthèses !

Un opérateur bien pratique, le `:`

Comment créer une suite d'entier ?

- `c(1, 2, 3, 4)`
- `seq(1, 4, 1`
- `1:4`

L'opérateur `:` est très utilisé en R. Sa syntaxe est la suivante

- $\texttt{i:j}$ va créer une suite d'entiers de $\texttt{i}$ à $\texttt{j}$. Les entiers peuvent être négatifs ou positifs, et on peut peut avoir $\texttt{i} < \texttt{j}$ ou $\texttt{i} > \texttt{j}$, ou même $\texttt{i} = \texttt{j}$.

Attention à bien mettre des **parenthèses** dans le cas d'entiers négatifs!

Exemples

- `3:7` : les entiers de 3 à 7
- `7:3` : les entiers de 7 à 7
- `-3:7` : les entiers de -3 à 7
- `-3:-7` : les entiers de -3 à -7
- `-(3:7)` : les entiers de -3 à -7

Assignation avec <-

Comment “sauvegarder” ces objets ?

En utilisant l’**opérateur d’assignation**

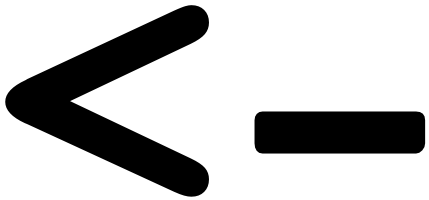

Utilisation de l'opération d'assignation

- A gauche : l'objet que l'on veut créer
- A droite : sa définition
- Lecture de l'opération : "assigner à cet objet (à gauche) le résultat de cette commande (à droite)"
- Assigner deux fois de suite écrasera la première valeur assignée
- Alternative : `=`
- Exemples : `a <- 1`, `b <- 1:10`, `a <- 2` etc.

Les noms d'objets

Règles absolues :

- Commence par une lettre ou un point, si le premier caractère est un point, le deuxième ne peut pas être un chiffre,
- Pas d'espace
- Pas de caractères correspondant à des opérations (`+`, `-`, `*`, `/`, `^`, `**`, etc.)
- Les minuscules et les majuscules sont différentes !
- Certains "mots-clefs" sont strictement interdits (`NA`, `TRUE`, `FALSE`, `for`, `if`, `else` etc.)
- MAIS on peut utiliser un nom d'objet qui existe déjà !

Bonnes pratiques :

- Utiliser un nom qui a du sens
- Ne pas utiliser des noms d'objets qui existent déjà et que l'on ne souhaite pas écraser !

Opérations

On peut appliquer des opérations à ces “vecteurs” !

```
a <- 1:5
a + 1
#> [1] 2 3 4 5 6
a * 2
#> [1]  2  4  6  8 10
```

Ces “vecteurs” sont des **objets**.

Les Objets

Classes d'objets

Nom	Appelation officielle	Exemple
Vecteur	`vector`	`1:10`
Facteur	`factor`	`gl(2, 2)`
Matrice	`matrix`	`matrix(1:4, 2, 2)`
Tableau	`data.frame`	`mtcars`
Liste	`list`	`list(a = 1, b = 1:10, c = "Hello!")`
Fonction	`function`	`sin`, `exp`, `log`

Pour connaître la classe d'un objet : `class(objet)`.

Types de données

Nom	Appellation officielle	Exemple
Entier ($\mathbb{Z}$)	`integer`	`1:10`, (ou `1L`)
Réel ($\mathbb{R}$)	`double`	`2.3`, `1/3`, etc…
Caractères	`character`	`month.name`, `"Bonjour"`
Booléen	`logical`	`TRUE`

Bouh les quoi ?

MATH., néol. Qui est relatif aux théories du logicien et mathématicien anglais George Boole.

– *Trésor de la Langue Française informatisé*

- `TRUE` (ou bien `T`) et `FALSE` (ou bien `F`)
- Résultat d'une comparaison : `==`, `!=`, `<`, `>`, `<=`, `>=`
- Opérations logiques : `!`, `&`, `|`, `xor`

Exercice

1. Effectuez les opérations suivantes :

- `1 == 2`
- `!(5 > -6)`
- `(1 <= 10) | (1 > 0)`

1. Prédisez le résultat de la commande suivante : `log(1) != 0`

“Classification” des objets

Les objets qui ne contiennent qu’un seul type de données : vecteurs et matrices.

Les objets pouvant contenir des données mixtes : tableaux et listes.

La flexibilité a un coût : on ne peut plus faire certaines opérations !

Les objets ayant des “dimensions” : vecteurs, tableaux et matrices

Les objets pour qui cela ne signifie rien ou presque : listes et fonctions

Les tableaux

```
data("fruits", package = "intro2r")
fruits
#>                                nom   groupe Energie  Eau Proteines
#> Abricot                    Abricot     crus     194 87.1      0.81
#> Abricot.1                  Abricot     secs    1010 24.7      2.88
#> Ananas                      Ananas exotique     304 81.3      0.94
#> Banane                      Banane exotique     383 75.8      1.06
#> Canneberge              Canneberge     secs    1410 14.6      0.25
#> Cerise                      Cerise     crus     235 85.7      0.81
#> Citron                      Citron     crus     118 91.3      0.25
#> Clementine              Clementine     crus     200 87.0      0.81
#> CompoteMultiFruits CompoteMultiFruits  compote     279 82.9      0.25
#> CompotePomme          CompotePomme  compote     432 72.9      0.23
#> Figue                        Figue     crus     293 80.2      1.19
#> Fraise                      Fraise     crus     162 90.3      0.63
#> Framboise                Framboise     crus     206 86.8      1.19
#> FruitCru                  FruitCru     crus     251 84.5      0.70
#> Grenade                    Grenade     crus     340 79.4      1.44
#> Groseille                Groseille     crus     289 82.1      1.56
#> Kaki                          Kaki exotique     290 81.8      0.88
#> Kiwi                          Kiwi exotique     255 83.5      0.88
#> Lime                          Lime exotique     170 86.3      1.13
#> Litchi                      Litchi exotique     344 80.5      1.13
#> Mangue                      Mangue exotique     376 77.1      0.75
#> Maracuja                  Maracuja exotique     425 73.6      2.13
#> Melange                    Melange     secs    1640 11.7      2.19
#> Melon                        Melon     crus     265 84.2      1.13
#> Mirabelle                Mirabelle     crus     325 78.1      0.63
```

Importer des données en R

- Des données de *packages* : `data`
- Des données au format R (`RData`) : `load`
- Des données “tabulées” : `read.table`
- Des données Excel : `openxlsx::read.xls`
- Des données Stata, SPSS, images etc.

Les données “de R”

- Utiliser la commande `data()` pour avoir une liste (presque ?) exhaustive.
- Bonne pratique : pour charger un jeu de données, utiliser la commande complète `data("nom_des_data", package = "nom_du_package")`
- Mais ces alternatives fonctionnent également :
  - `data(mtcars)`
  - `DNase`
  - `library(ggplot2) ; data(diamonds)`

Utilisation des guillemets

- Obligation : quand l'argument doit être une chaîne de caractères
- Oubli : `library`, `require`, `data`
- Guillemets simples : fonctionnent comme les guillemets doubles. Ex.: `"bonjour"` est équivalent à `'bonjour'`.
- Le "backtick" ou "backquote" : "`"

Explorer les données `fruits`

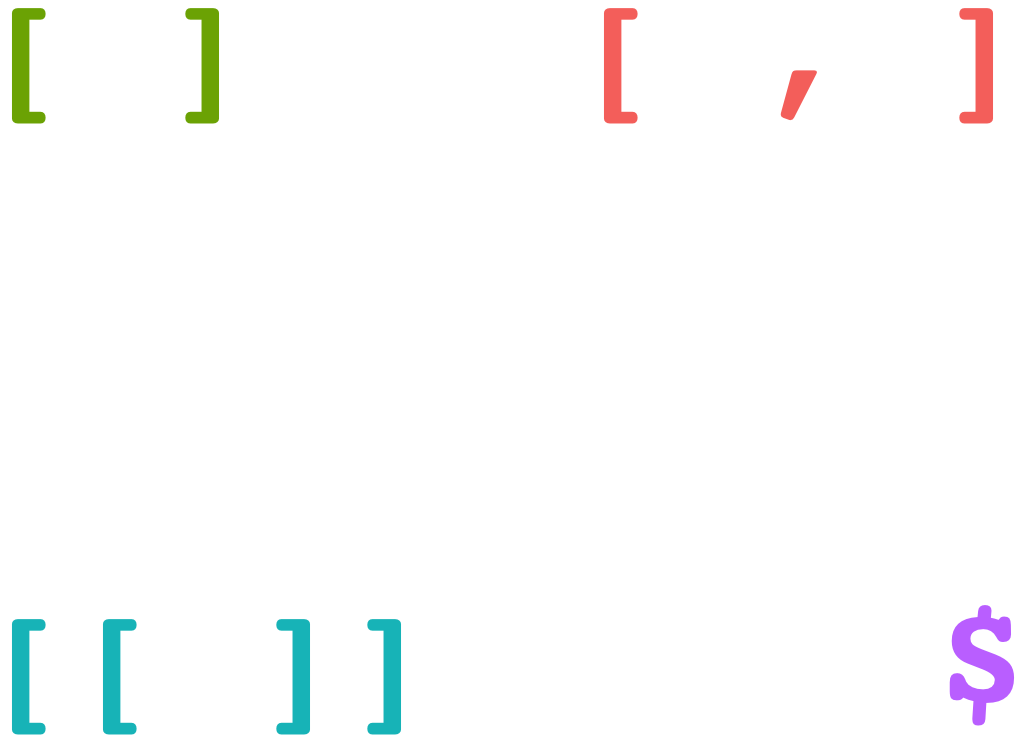

Sur quels objets les utiliser ?

Opérateur	Vecteurs	Matrices	Tableaux	Listes
`[ ]`	x		x	x
`[ , ]`		x	x	
`[[ ]]`			x	x
`$`			x	x

L'opérateur de sélection classique : `[ , ]`

- Pour sélectionner la première ligne : `fruits[1, ]`
- Pour sélectionner la deuxième colonne : `fruits[, 2]`
- Pour enlever la troisième ligne : `fruits[-3, ]`
- Pour enlever la quatrième colonne : `fruits[, -4]`

Sélectionner plusieurs lignes / colonnes

- Pour sélectionner les lignes 1 et 3 : `fruits[c(1, 3), ]`
- Pour sélectionner les colonnes 2 et 4 : `fruits[, c(2, 4)]`
- Pour enlever les lignes 5 et 7 : `fruits[-c(5, 7), ]`
- Pour enlever les colonnes 6 et 8 : `fruits[, -c(6, 8)]`

De l'utilité des deux points

Pour sélectionner une plage entière de lignes ou de colonnes adjacentes :

- Pour sélectionner les lignes 11 à 17 : `fruits[11:17, ]`
- Pour sélectionner les colonnes 3 à 5 : `fruits[, 3:5]`
- Pour enlever les trois premiers fruits : `fruits[-(1:3), ]`
- Pour enlever les cinq premières variables : `fruits[, -(1:5)]`

Exercice

Que se passe-t-il quand on oublie les parenthèses dans la commande `fruits[-(1:3), ]` ? Commentez !

Faites de même avec le jeu de données `mtcars`.

Pour extraire une seule colonne : le `$`

La syntaxe `donnees$cible` permet de sélectionner la colonne `cible` du tableau `donnees`.

- Par exemple : `fruits$Eau`
- Autre exemple : `fruits$groupe`

Exercice

Extrayez la colonne de la teneur en sucres de la table des fruits… de deux façons différentes !

Créez un objet contenant la teneur en sucres : quelle est la classe de cet objet ?

Les vecteurs…

- … sont “unidimensionnels”
- … ont une classe qui est égale au type de données qu’ils contiennent (R !!!)
- … sont indexés avec des crochets simples

Exemples :

- `i <- 1:10`
- `eau <- fruits$Eau`
- `eau[i]`

Exercice

Créez un vecteur `groupe` contenant les groupes de fruits. Donnez deux façons différentes d'extraire les dix premières valeurs de ce vecteur.

Extraction avec des Booléens

Comment extraire les fruits … * dont la teneur en eau est supérieure à 60 ? * exotiques ? * secs contenant moins de 40g/100g de sucres ?

Réponse : en utilisant des vecteurs booléens

1. Créer le vecteur de booléens `fruits$Eau >= 60`
2. Utiliser le résultat dans les crochets carrés `fruits[fruits$Eau >= 60, ]`

Ne pas oublier la virgule !

Le principe

Pour un vecteur `v` :

- `v[bool]` extrait les valeurs de `v` pour lesquelles `bool` est vrai (`TRUE`).
  Contrainte : `v` et `bool` doivent contenir **le même nombre d'éléments**.

Pour un tableau `tab` :

- `tab[brow, ]` pour extraire les lignes
- `tab[, bcol]`
- Contrainte 1 : `brow` doit avoir autant d'éléments que `tab` de lignes
- Contrainte 2 : `bcol` doit avoir autant d'éléments que `tab` de colonnes

Attention

Vous verrez souvent des opérations logiques à l'intérieur des crochets carrés : cela permet d'aller plus vite !

Par exemple, en deux étapes :

1. `bool <- fruits$groupe == "secs" & fruits$Sucres < 40`
2. `fruits[bool, ]`

Devient, en une étape :

- `fruits[fruits$groupe == "secs" & fruits$Sucres < 40, ]`

Attention bis

On peut combiner deux méthodes d'extraction de données pour un tableau : une sur les lignes et une sur les colonnes !

Par exemple : `tab[brow, icol]`, où `brow` est un vecteur de booléens et `icol` un vecteur d'indices.

Exercice

Construisez la sous-table contenant la teneur en protéines, en glucides et en lipides des fruits secs.

Les objets nommés

En R, on peut donner des “noms”…

- aux éléments d’un vecteur,
- aux lignes d’un tableau ou d’une matrice,
- aux colonnes d’un tableau ou d’une matrice,
- aux éléments d’une liste

Pourquoi ? Pour pouvoir disposer d’une nouvelle méthode d’extraction de données !

Pour un tableau

On utilise :

- `rownames(tab)` pour connaître le nom des lignes
- `colnames(tab)` pour connaître le nom des colonnes

Et, en bonus, on peut :

- changer les noms des lignes `rownames(tab) <- new1`
- changer les noms des colonnes `colnames(tab) <- new2`

Et, en super bonus, on peut :

- modifier quelques noms de lignes `rownames(tab)[sel1] <- new1`
- modifier quelques noms de colonnes `rownames(tab)[sel1] <- new2`

Modifier un objet ou son contenu

La syntaxe `obj[i] <- newvalue` (et ses variations) peut être utilisée pour tous les types d'objets indiçables. Mais il faut l'utiliser avec prudence !

Exemple : `fruits$Energie[1:10] <- 0`

Que s'est-il passé ? **Au secours !!!!**

Pour revenir en arrière : `data("fruits", package = "intro2r")`

Extraction avec des noms

Exemple :

- Pour extraire l'énergie : `fruits[, "Energie"]`,
- Pour extraire le groupe : `fruits[, "groupe"]`,
- Pour extraire l'énergie et le groupe : `fruits[, c("Energie", "groupe")]`,
- Pour enlever le groupe : `fruits[, -"groupe"]` ?

Bilan

Mode d'extraction	Exemples
Indices	`fruits[, 2]`
Booléens	`fruits[fruits$nom == "Abricot", ]`
Noms	`fruits$nom` ou `fruits[,"nom"]`

Exercice

Lister le maximum de façons possibles d'extraire du tableau `fruits` les fruits crus sucrés riches en Vitamine C !

Construire ses propres objets

Vecteurs et facteurs

- La fonction `c()` permet de combiner des valeurs dans un vecteur. Attention, tout doit être du même “type” !
- La fonction `seq` permet de créer des suites.
- La fonction `rep` permet de créer des vecteurs en répétant des valeurs. Ex: `rep(c("a", "b"), c(3, 4))`

Les facteurs sont une particularité de R !

- On les crée avec la fonction `factor` ou `as.factor`
- Par exemple : `factor(fruits$groupe)`

Matrices et tableaux

- Les fonctions `matrix`, `rbind` et `cbind` pour créer des matrices. Attention, tout doit être du même “type” !
- Les fonctions `data.frame` ou `as.data.frame` pour créer des

Ajouter des noms

Directement à la création de l'objet. Ex: `x <- c(a = 1, b = 2)`,`d <- data.frame(a = 1:26, b = letters)`

Ou bien après la création de l'objet :

- `names(obj) <- lesNoms` pour un vecteur
- `rownames(obj) <- lesLignes` pour les lignes d'un tableau ou d'une matrice,
- `colnames(obj) <- lesColonnes` pour les colonnes d'un tableau ou d'une matrice.

Exercice

Créez un facteur à partir des groupes de fruits, puis testez la commande suivante :

```
factor(fruits$groupe, levels = c("secs", "compote", "crus", "exotique"))
```

Que se passe-t-il ? Sauvez le résultat dans un objet et faites un diagramme en bâton avec ! Commentez !

Estimation ponctuelle

Définition

Il s'agit d'estimer un caractéristique statistique d'un ensemble de données avec une seule valeur.

Paramètre	Grandeur statistique	Commande
Position	Moyenne	`mean`
Position	Médiane	`median`
Position	Minimum	`min`
Position	Maximum	`max`
Dispersion	Variance	`var`
Dispersion	Ecart-type	`sd`
Dispersion	Intervalle inter-quartiles	`IQR`
Lien	Covariance	`cov`
Lien	Corrélation	`cor`

Rappel : la covariance

Permet de mesurer le degré de co-variation de deux variables :

$$\mathrm{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - m_x)\left(y_i - m_y\right)$$

Rappel : corrélation de Pearson

C'est une covariance normalisée entre -1 et 1 !

$$\text{cor}(x, y) = \frac{\text{cov}(x, y)}{\sqrt{\text{var}(x)}\sqrt{\text{var}(y)}}$$

Rappel : corrélation de Spearman

C'est la corrélation (de Pearson) calculée sur les rangs !

$$\rho = \text{cor}(r_x, r_y),$$

avec r_x le vecteur des rangs de x (`rank(x)`), et r_y le vecteur des rangs de y (`rank(y)`).

Rappel (?) : corrélation de Kendall

- Paire concordante : $\left(x_i < x_j \text{ et } y_i < y_j\right)$ OU $\left(x_i > x_j \text{ et } y_i > y_j\right)$
- Paire discordante : $\left(x_i < x_j \text{ et } y_i > y_j\right)$ OU $\left(x_i > x_j \text{ et } y_i < y_j\right)$

$$\tau = \frac{n_C - n_D}{n_0},$$

avec n_C le nombre de paires concordantes, n_D le nombre de paires discordantes et n_0 le nombre total de paires de points.

Exercice

Calculez

- la médiane de la teneur en sucres
- la moyenne de la teneur en eau
- l'écart-type de la teneur en eau

Appliquez la fonction `summary` aux données `fruits`.

- Calculez la corrélation de Pearson entre la teneur en eau et la teneur en sucres,
- Calculez la corrélation de Spearman

Les fonctions astucieuses

- `summary` pour obtenir des statistiques
- `str` pour la structure des données
- `table` pour faire des tables de comptage
- `seq_along` pour créer un vecteur d'indices de même longueur qu'un vecteur donné

D’autres fonctions très utilies

- `sum` pour calculer la somme de nombres
- `sort`, `order` et `rank` pour ordonner, et calculer les rangs
- `rowSums` et `colSums` pour calculer les sommes des lignes et colonnes d’une table,
- `rowMeans` et `colMeans` pour calculer les moyennes des lignes et colonnes d’une table,

Les graphes de base

- `barplot` : diagrammes en bâtons
- `hist` : histogrammes
- `plot` : nuages de points

La fonction `barplot`

Permet de réaliser des diagrammes en bâtons :

```
barplot(table(fruits$groupe))
```

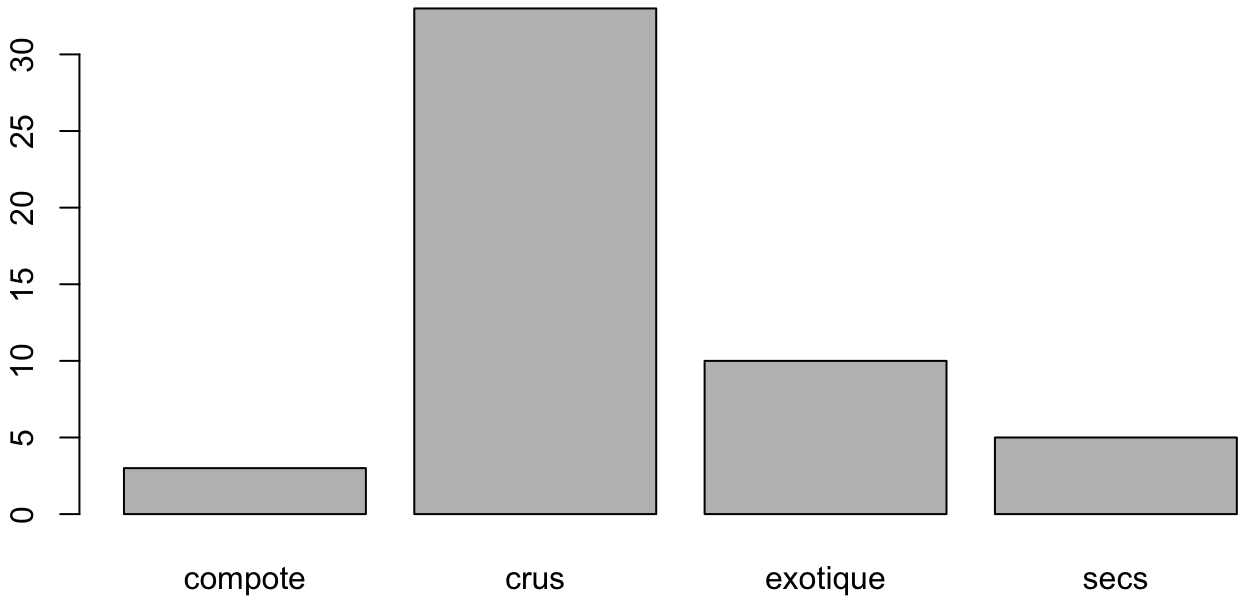

La fonction `hist`

Permet de réaliser des histogrammes :

```
hist(fruits$Eau)
```

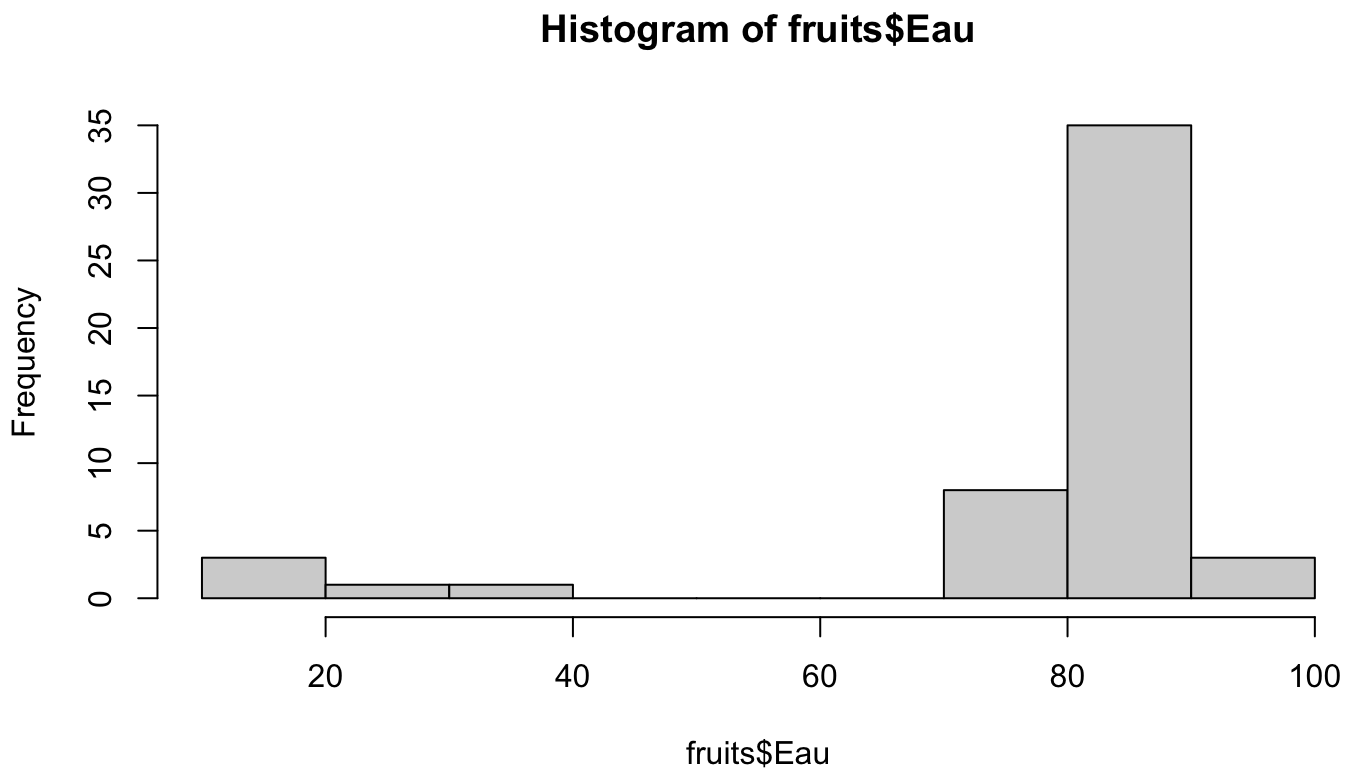

La fonction `plot`

Permet de tracer des nuages de points :

```
plot(fruits$Eau, fruits$Sucres)
```

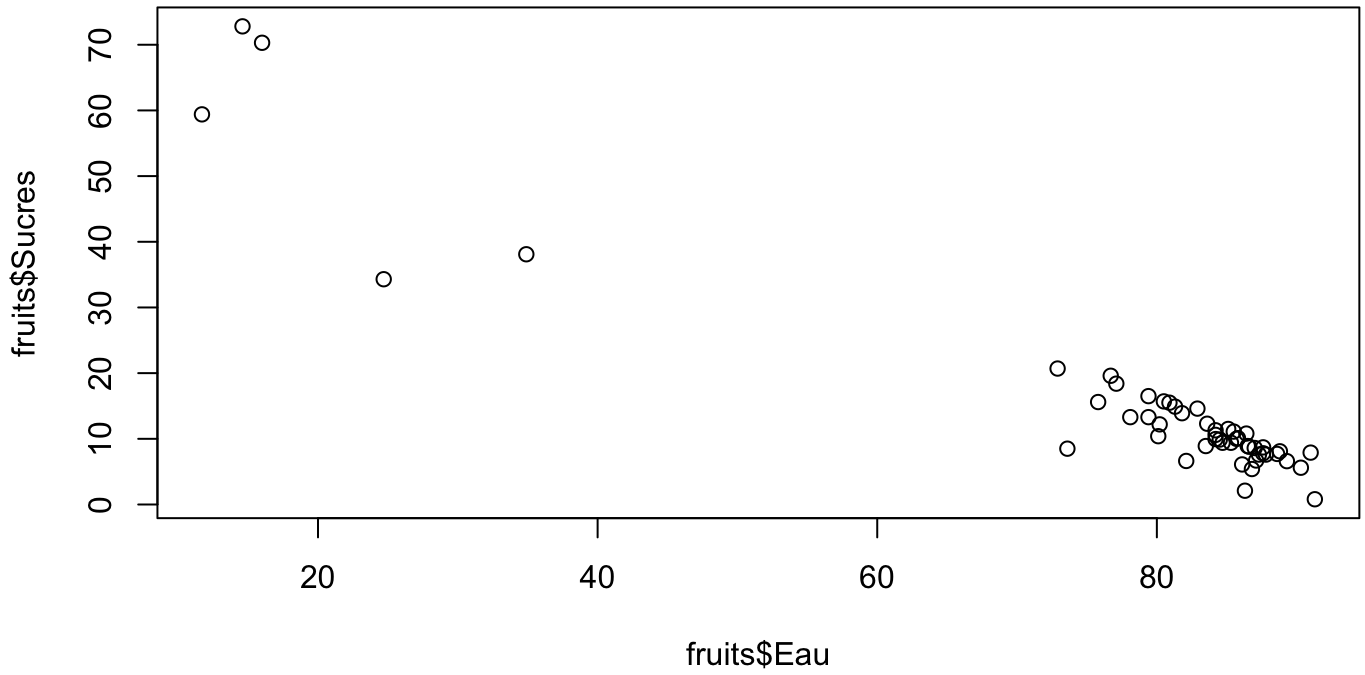

Exercice

Faire un histogramme de la teneur en Vitamine C des fruits crus.

Import de données

Rappels sur les fonctions

Lire des fichiers tabulés : `read.table`, `read.csv`, `read.csv2`, `read.delim`, `read.delim2`.

Lire des fichiers Excel : `openxlsx::read.xlsx`(, `readxl::read_excel`)

Mais on peut utiliser aussi le menu “Import Dataset” de Rstudio !

Exercice

1. Téléchargez les données Nutriwi (https://vguillemot.github.io/intro2r/inst/extdata/nutrimenu.csv).
2. Placez ces données dans votre **dossier de travail**
3. Importez ces données dans votre **environnement**
4. Explorez rapidement les données Nutriwi avec les fonctions `class`, `dim`, `summary` etc.